

Contents

EVIDENCE: Derivasi Persamaan Fisika, Matematika & Statistika — IDA-PTW v59	3
DAFTAR PERSAMAAN	4
Bagian I — Fisika Seismologi (10 persamaan)	4
Bagian II — Statistika Gempa Bumi (4 persamaan)	4
Bagian III — Machine Learning (5 persamaan)	4
Bagian IV — Operasional & Optimasi (2 persamaan)	4
BAGIAN I — FISIKA SEISMOLOGI	4
I.1 — $S_a(T)$ via Nigam–Jennings	4
Persamaan umum	4
Derivasi solusi closed-form (Nigam–Jennings 1969)	5
Implementasi: <code>src/physics/psa_calculator.py</code>	5
Makna fisis	5
Relasi ke audit	5
I.1a — Korelasi T (periode struktur) tinggi gedung & respon	5
Persamaan empiris fundamental period	5
Derivasi: rule of thumb $T \approx 0.1N$	6
Derivasi fisis: pendulum + cantilever beam	6
Implementation di sistem desain (manuscript Sec 1)	6
Mapping T kategori gedung	6
Resonansi: kenapa $S_a(T)$ matters	7
Site-source-structure resonance triple	7
Periode anchor SNI 1726:2019 vs grid 103 periode IDA-PTW	7
Periode anchor IDA-PTW di Tab. 17 — alasan pemilihan	8
Resonansi vs frekuensi dominan ground motion (Brune)	8
Implementasi di pipeline (mapping persamaan ke kode)	8
Makna fisis ringkas	9
Relasi ke audit	9
Referensi standar bangunan	9
I.2 — τ_c (Kanamori 2005)	9
Persamaan umum	9
Derivasi	9
Implementasi: <code>src/physics/feature_extractor.py:44-79</code>	10
Makna fisis	10
Relasi ke audit	10
I.3 — P_d (Wu & Kanamori 2005)	10
Persamaan umum	10
Derivasi	10
Implementasi: <code>src/physics/feature_extractor.py:82-107</code>	10
Makna fisis	11
Relasi ke audit	11
I.4 — CAV (EPRI 1988)	11
Persamaan umum	11
Derivasi	11
Implementasi: <code>src/physics/feature_extractor.py:110-136</code>	11
Makna fisis	11
Relasi ke audit	12
I.5 — IV^2 (Arias 1970 proxy)	12
Persamaan umum	12
Derivasi	12
Implementasi: <code>src/physics/feature_extractor.py:139-169</code>	12
Makna fisis	12
Relasi ke audit	12
I.6 — H/V ratio (Nakamura 1989)	13
Persamaan umum	13

Derivasi	13
Implementasi: src/physics/feature_extractor.py:172-202	13
Makna fisis	13
Relasi ke audit	13
I.7 — Brune source spectrum (1970)	13
Persamaan umum	13
Derivasi corner frequency	13
Implementasi (implicit via τ_c)	14
Makna fisis	14
Relasi ke audit	14
I.8 — P-S travel time & Golden Time	14
Persamaan umum	14
Derivasi Golden Time constraint	15
Implementasi: task15_stage1_ensemble_optuna.py	15
Makna fisis	15
Relasi ke audit	15
I.9 — Unit conversion g gal	15
Persamaan	15
Derivasi	15
Implementasi: src/physics/psa_calculator.py:92	15
Relasi ke audit	15
BAGIAN II — STATISTIKA GEMPA BUMI	16
II.1 — Atkinson–Boore GMPE log-linear	16
Persamaan umum	16
Derivasi parameter	16
Implementasi: task16_gmpe_baseline.py:70-90	16
Makna fisis	16
Relasi ke audit	16
II.2 — Al Atik (2010) sigma decomposition	17
Persamaan umum	17
Derivasi mixed-effects model	17
Implementasi: task4_sigma_decomposition.py:111-123	17
Makna fisis & statistis	17
Relasi ke audit	17
II.3 — Marginalized R^2 over Stage-1 posterior	18
Persamaan umum	18
Derivasi	18
Tiga varian R^2 yang dilaporkan	18
Implementasi: task15_stage1_ensemble_optuna.py:427-431	18
Makna statistis	18
Relasi ke audit	19
II.4 — Balanced accuracy (multi-class)	19
Persamaan	19
Derivasi vs accuracy biasa	19
Implementasi: task15_stage1_ensemble_optuna.py:392	19
Makna safety-relevant	19
Relasi ke audit	19
BAGIAN III — MACHINE LEARNING	19
III.1 — XGBoost objective	19
Persamaan umum	19
Derivasi second-order Taylor expansion	20
Implementasi: manuscript Sec 4.5 + task15:366-371	20
Makna ML-statistik	20
Relasi ke audit	21
III.2 — Gradient boosting recursion	21

Persamaan	21
Derivasi	21
Implementasi (implicit via XGB library)	21
Makna ML	21
Relasi ke audit	21
III.3 — SMOTE	22
Persamaan	22
Derivasi	22
Implementasi: task15:354-356	22
Makna ML	22
Relasi ke audit	22
III.4 — Soft voting ensemble	22
Persamaan	22
Derivasi	23
Implementasi: task15:387	23
Makna ML	23
Relasi ke audit	23
III.5 — TPE Optuna	23
Persamaan	23
Derivasi Expected Improvement	23
Implementasi: task15:111-152	23
Makna optimization	24
Relasi ke audit	24
BAGIAN IV — OPERASIONAL & OPTIMASI	24
IV.1 — Multi-objective Lagrangian	24
Persamaan	24
Derivasi	24
Implementasi (logical, distributed across tasks)	25
Makna design philosophy	25
Relasi ke audit	25
IV.2 — Adaptive PTW selection rule	25
Persamaan	25
Derivasi	25
Implementasi (via class-conditional Stage 2)	25
Makna physical adaptation	26
Relasi ke audit	26
RINGKASAN: PERSAMAAN ANGKA HEADLINE	26
REFERENSI LITERATUR UTAMA	27
CERTIFICATION	27

EVIDENCE: Derivasi Persamaan Fisika, Matematika & Statistika — IDA-PTW v59

Dokumen pendamping EVIDENCE_v59_numbers.md. Setiap persamaan di manuscript v59 di-derivasi dari **persamaan umum literatur bentuk yang digunakan implementasi di source code makna fis/statistis**.

Audiens: penguji disertai S3 Fisika UI. **Target:** setiap baris kode di pipeline task1–task17 dapat ditelusuri ke persamaan fundamental dengan referensi literatur eksplisit.

DAFTAR PERSAMAAN

Bagian I — Fisika Seismologi (10 persamaan)

1. Pseudo-Spectral Acceleration $S_a(T)$ via Nigam–Jennings
 - I.1a — Korelasi T (periode) tinggi gedung & respon struktural
2. Periode dominan τ_c (Kanamori 2005)
3. Peak displacement P_d (Wu & Kanamori 2005)
4. Cumulative Absolute Velocity (CAV, EPRI 1988)
5. Integral velocity squared / Arias intensity proxy IV^2
6. Nakamura H/V ratio
7. Brune source spectrum / corner frequency
8. P-S travel time & Golden Time budget
9. Unit conversion g gal

Bagian II — Statistika Gempa Bumi (4 persamaan)

10. Atkinson–Boore GMPE log-linear form
11. Al Atik (2010) mixed-effects sigma decomposition
12. Marginalized R^2 over Stage-1 posterior
13. Balanced accuracy (multi-class)

Bagian III — Machine Learning (5 persamaan)

14. XGBoost gradient-boosting objective + regularization
15. Gradient boosting tree update recursion
16. SMOTE synthetic minority oversampling
17. Soft-voting ensemble probabilistic fusion
18. TPE (Tree-structured Parzen Estimator) Optuna sampler

Bagian IV — Operasional & Optimasi (2 persamaan)

19. Multi-objective Lagrangian (Stage-2 training loss)
20. Adaptive PTW selection rule

BAGIAN I — FISIKA SEISMOLOGI

I.1 — $S_a(T)$ via Nigam–Jennings

Persamaan umum

Pseudo-Spectral Acceleration $S_a(T)$ adalah respons puncak osilator linier elastis Single-Degree-of-Freedom (SDOF) terhadap akselerasi dasar $\ddot{u}_g(t)$. Persamaan gerak Newton (Chopra 2017, Ch. 6):

$$\ddot{x}(t) + 2\zeta\omega_0 \dot{x}(t) + \omega_0^2 x(t) = -\ddot{u}_g(t) \quad (\text{I.1.1})$$

di mana: $x(t)$ = perpindahan relatif osilator terhadap dasar [m] - $\omega_0 = 2\pi/T$ = frekuensi sudut natural osilator [rad/s] - ζ = rasio redaman (=0.05 untuk konvensi “PSA5%”) - $\ddot{u}_g(t)$ = akselerasi tanah yang diukur [m/s²]

$S_a(T)$ didefinisikan:

$$S_a(T) = \omega_0^2 \cdot \max_t |x(t)| \quad (\text{I.1.2})$$

Derivasi solusi closed-form (Nigam–Jennings 1969)

Asumsikan $\ddot{u}_g(\tau)$ linear piecewise di antara dua sample berturut-turut $\ddot{u}_n$ dan $\ddot{u}_{n+1}$, sample interval Δt :

$$\ddot{u}_g(\tau) = \alpha + \beta\tau, \quad \alpha = \ddot{u}_n, \quad \beta = \frac{\ddot{u}_{n+1} - \ddot{u}_n}{\Delta t} \quad (1.1.3)$$

Solusi variation-of-parameters dari ODE (1.1.1) dengan forcing (1.1.3) memberikan **closed-form update state** dari sample n ke $n+1$ (Chopra 2017, App. A):

$$\begin{aligned} x_{n+1} &= A_{11}x_n + A_{12}\dot{x}_n + B_{11}\ddot{u}_n + B_{12}\ddot{u}_{n+1} \\ \dot{x}_{n+1} &= A_{21}x_n + A_{22}\dot{x}_n + B_{21}\ddot{u}_n + B_{22}\ddot{u}_{n+1} \end{aligned} \quad (1.1.4)$$

dengan koefisien A_{ij} , B_{ij} fungsi tertutup dari ω_0 , ζ , Δt . **Solusi eksak** — error tunggal hanya dari pilihan Δt .

Implementasi: src/physics/psa_calculator.py

```
# Lines 27–39: Equation of motion
"""
 $\ddot{x} + 2\zeta\omega_0\dot{x} + \omega_0^2x = -\ddot{u}_g(t)$  (Eq. 1)
 $PSA(T) = \omega_0^2 \cdot \max |x(t)|$  (Eq. 2)
"""
# Lines 41–57: Piecewise-linear closed-form update (Eq. 3a/3b)
# Lines 90–92:
G_MS2 = 9.80665 # standard gravity for unit conversion
```

Pipeline upstream: SeisComP3 scwfparam 4-pole Butterworth bandpass + Nigam–Jennings (verified line-by-line equivalent).

Makna fisis

- $Sa(T)$ mewakili **demand struktural** pada bangunan dengan periode natural T . SNI 1726:2019 dan ASCE/SEI 7-16 menggunakan kurva $Sa(T)$ untuk desain seismik gedung — bukan PGA.
- $T = 0$: osilator infinitely stiff mengikuti input $Sa(0) \equiv \text{PGA}$.
- $T = \infty$: osilator floppy tidak merespons $Sa(\infty) = 0$.
- Pada periode struktur tipikal $T \in [0.2, 2.0]$ s, $Sa(T)$ adalah ukuran beban gempa yang paling representatif untuk bangunan 2-20 lantai.

Relasi ke audit

- **103 periode** target: $T = 0.051, 0.101, \dots, 10.0$ s mengikuti grid IBC/ASCE.
- Headline $R^2 = 0.7091$ adalah akurasi prediksi vektor 103-dimensi $[\log_{10} Sa(T_1), \dots, \log_{10} Sa(T_{103})]$.

1.1a — Korelasi T (periode struktur) tinggi gedung & respon

Persamaan empiris fundamental period

Periode natural getaran gedung berkorelasi dengan tinggi. SNI 1726:2019 §7.8.2.1 dan ASCE/SEI 7-16 §12.8.2.1 mengadopsi formula empiris:

$$T_a = C_t h_n^x \quad (1.1a.1)$$

di mana: - T_a = approximate fundamental period [s] - h_n = tinggi struktur dari basis ke level atap [m] - C_t , x = koefisien empiris (tergantung sistem struktur)

Sistem struktur	C_t (SI)	x
Steel moment-resisting frame (SMRF)	0.0724	0.8
Concrete moment-resisting frame (RC-MRF)	0.0466	0.9
Eccentrically braced steel frame	0.0731	0.75
All other systems	0.0488	0.75

Derivasi: rule of thumb $T \approx 0.1N$

Untuk RC-MRF dengan tinggi tipikal lantai $h_{\text{floor}} \approx 3.5$ m, gedung N lantai memiliki $h_n = 3.5 N$:

$$T_a = 0.0466 \times (3.5N)^{0.9} = 0.0466 \times 3.5^{0.9} \times N^{0.9} \approx 0.147 \times N^{0.9}$$

Untuk N dalam range 5–30 lantai: $N^{0.9} \approx 0.7 N$ (rough), sehingga:

$$T_a \approx 0.1N \quad (\text{rule of thumb}) \quad (1.1a.2)$$

Misal: gedung 10 lantai $T_a \approx 1.0$ s; gedung 20 lantai $T_a \approx 2.0$ s. **Ini adalah alasan fisis mengapa $T = 1.0$ s menjadi anchor period utama di Tab. 17 manuscript** — mewakili mid-rise (~10-lantai) yang adalah profil bangunan dominan di Jakarta, Surabaya, Bandung.

Derivasi fisis: pendulum + cantilever beam

Single-degree-of-freedom approximation: gedung dapat dimodelkan sebagai cantilever beam dengan massa terdistribusi m , kekakuan lateral k . Frekuensi natural:

$$f_n = \frac{1}{2\pi} \sqrt{\frac{k}{m}} \Rightarrow T_n = 2\pi \sqrt{\frac{m}{k}} \quad (1.1a.3)$$

Untuk cantilever beam: - $m \propto h_n$ (massa proporsional terhadap tinggi) - $k \propto EI/h_n^3$ (kekakuan menurun pangkat 3 tinggi)

Sehingga:

$$T_n \propto \sqrt{\frac{h_n}{EI/h_n^3}} = \sqrt{\frac{h_n^4}{EI}} \propto h_n^2$$

Pangkat teoretik $x = 2$, tapi empiris $x \approx 0.75\text{--}0.9$ karena: (1) gedung tidak homogen — EI bervariasi per lantai, (2) kontribusi shear deformation di lantai bawah, (3) participation faktor mode tinggi. Coding standard pakai empirical fit dari ratusan bangunan ter-instrumentasi.

Implementation di sistem desain (manuscript Sec 1)

Manuscript Sec 1 line 67: “SNI 1726:2019 [ref12] and ASCE/SEI 7-16 [ref13] both require 5%-damped spectral acceleration $S_a(T)$ at the structure period, not peak ground acceleration alone.”

Mapping T kategori gedung

Range T (s)	N lantai ($\approx$)	Kategori bangunan	Kerentanan tipikal
0.05–0.2	1–2	Bangunan rendah / equipment	Masonry rumah, gedung 1-lantai, mesin industri rigid
0.2–0.5	2–5	Low-rise residential	Rumah toko, ruko, sekolah 2-3 lantai (mayoritas di Indonesia)
0.5–1.0	5–10	Mid-rise commercial	Hotel, kantor, mall, RS 5–10 lantai (Jakarta CBD low-mid)
1.0–2.0	10–20	High-rise □ paling vulnerable di Indonesia	Apartemen 15–20 lantai, perkantoran Jakarta-Selatan
2.0–3.0	20–30	Very high-rise	Office tower 25–30 lantai, BCA Tower, Wisma 46
3.0–5.0	30–50	Super-tall	Menara tipe Pacific Place, Equity Tower
5.0–10.0	50+	Special / very-long-period	Suspension bridge, dome stadium, fiber-glass tower

Resonansi: kenapa $S_a(T)$ matters

Gedung dengan periode natural T_n mengalami **amplifikasi maksimum** ketika input ground motion punya energi konsentrasi di periode tersebut. Transfer function SDOF:

$$|H(\omega)|^2 = \frac{1}{(1-r^2)^2 + (2\zeta r)^2}, \quad r = \omega/\omega_n \quad (1.1a.4)$$

Pada resonansi $\omega = \omega_n$ ($r = 1$):

$$|H|_{max} = \frac{1}{2\zeta} = \frac{1}{0.10} = 10 \times \quad (\text{untuk } \zeta = 0.05)$$

Artinya: input ground motion $S_a(T_n) = 0.1 \text{ g}$ di periode resonansi akselerasi internal gedung **10x lebih besar** = 1.0 g . Inilah mengapa kelas bangunan tertentu (T tertentu) lebih vulnerable terhadap source spectrum tertentu.

Site-source-structure resonance triple

Skenario sangat-vulnerable: 1. **Source:** gempa subduksi $M \sim 7$ corner frequency $f_c \approx 0.3 \text{ Hz}$ ($T_c \approx 3 \text{ s}$) — energi dominan di periode panjang 2. **Path/Site:** tanah lunak Jakarta basin (cekungan dalam 100-300 m) amplifikasi $T = 1\text{--}3 \text{ s}$ (Nakamura H/V peak) 3. **Structure:** high-rise 15–20 lantai dengan $T_n \approx 1.5\text{--}2.0 \text{ s}$

Ketiga overlap di $T \approx 1.5\text{--}2.0 \text{ s}$ **demand spectrum** di periode ini akan **paling tinggi** gedung 15-20 lantai paling berisiko. Inilah skenario disain SNI 1726:2019 untuk Jakarta.

Sebaliknya, gempa shallow crustal $M \sim 5$ (Cianjur 2022, Sumedang 2024) $f_c \approx 1\text{--}3 \text{ Hz}$ ($T_c \approx 0.3\text{--}1 \text{ s}$) membahayakan **low-rise residential** (rumah, ruko 2-3 lantai) — yang adalah profil bangunan korban Cianjur 2022.

Periode anchor SNI 1726:2019 vs grid 103 periode IDA-PTW

SNI 1726:2019 mendefinisikan **2 anchor period** untuk peta desain: - $S_{S1} \square S_a(T = 0.2 \text{ s}) = \text{MCE}_R$ short-period spectral acceleration (low-rise design) - $S_{S1} \square S_a(T = 1.0 \text{ s}) = \text{MCE}_R$ 1-second spectral acceleration (mid/high-rise design)

Plus turunan S_{DS} , S_{D1} untuk design earthquake ($\times 2/3$ faktor MCE DBE).

Grid 103-periode IDA-PTW **superset** dari SNI anchor — output $S_a(T)$ di seluruh range 0.051–10 s, sehingga: - Desainer dapat ekstrak S_S , S_1 langsung untuk SNI compliance - Plus mendapatkan kurva spektrum **lengkap** untuk performance-based design (NSP, NDP, IDA per FEMA P-58) - Mendukung response spectrum analysis untuk SEMUA kategori bangunan (1–50+ lantai)

Periode anchor IDA-PTW di Tab. 17 — alasan pemilihan

Anchor T	Alasan dipilih	Kategori didukung
0.3 s	SNI S_S proxy + low-rise residential (mayoritas korban gempa Indonesia)	Rumah, ruko, RSUD 2-5 lantai
0.5 s	Mid-low rise transition	Hotel/sekolah 4-7 lantai
1.0 s	SNI S_1 direct + mid-rise dominant Jakarta	Kantor 10-lantai (anchor utama)
3.0 s	High-rise + suspension bridge proxy	Apartment 20–30 lantai

Tab. 17 melaporkan sigma decomposition di 7 anchor periode memberikan **engineering-actionable uncertainty** untuk setiap kategori bangunan utama.

Resonansi vs frekuensi dominan ground motion (Brune)

Source spectrum Brune (lihat I.7) punya corner frequency $f_c \propto M_0^{-1/3}$. Untuk magnitudo dataset IDA-PTW (M_w 1.7–6.2):

M_w	Brune f_c (Hz)	T_c (s)	Resonance ke gedung
4.0	~5 Hz	0.2 s	Low-rise 1-3 lantai
5.0	~2 Hz	0.5 s	Mid-low rise 4-6 lantai
5.5 (Cianjur)	~1.3 Hz	0.8 s	Mid-rise 6-10 lantai
6.0	~0.8 Hz	1.2 s	High-rise 10-15 lantai
6.2 (Garut)	~0.6 Hz	1.7 s	High-rise 15-20 lantai

Insight saturation-aware: untuk event $M_w > 6.5$ (rupture > 5 detik), f_c semakin rendah energi bergeser ke periode panjang **gedung tinggi paling berisiko**. Inilah mengapa Stage 2 IDA-PTW perlu observasi 8 detik untuk kelas Damaging — menangkap konten frekuensi-rendah yang relevan untuk gedung tinggi yang paling vulnerable.

Implementasi di pipeline (mapping persamaan ke kode)

Pipeline IDA-PTW tidak menghitung $T_a = C_t h_n^x$ langsung (gedung dispesifikan downstream oleh user). Tapi pipeline **menyediakan $S_a(T)$ di 103 periode** sehingga user/code:

```
# Skenario downstream user (engineering office):
sa_curve = ida_ptw.predict(waveform_p3s) # shape (103,) = log10 Sa(T_i)
T_grid = np.array([0.051, 0.101, ..., 10.0]) # 103 periods

# Untuk gedung 15-lantai RC-MRF:
h_n = 15 * 3.5 # 52.5 m
T_a = 0.0466 * h_n**0.9 # ≈ 1.62 s
# Interpolasi Sa di T_a:
sa_at_building = np.interp(T_a, T_grid, sa_curve)
# Compare dengan SNI 1726:2019 design spectrum:
sa_design_sni = compute_sni_design_spectrum(zone_indonesia, T_a)
# Decision: alert structural engineer if sa_at_building > sa_design_sni
```


Makna fisis ringkas

- **T adalah parameter struktural, bukan source:** $S_a(T)$ bertanya “berapa peak response struktur SDOF dengan periode natural T ?”
- **Higher T = taller building:** rule of thumb $T \approx 0.1N$
- **Resonansi:** ground motion paling merusak ketika spektrum input punya energi di $T = T_n$ struktur
- **Triple resonance** (source f_c + site amplification + structure T_n) menentukan worst-case scenario
- **103 periode IDA-PTW** mendukung **semua kategori bangunan** Indonesia (1–50 lantai)

Relasi ke audit

- **103 periode** = grid mendukung 1–50 lantai gedung Indonesia
- **$\sigma_{total} = 0.862$ di $T=1.0$ s** (Tab. 17/19) — uncertainty untuk gedung 10-lantai (kategori dominan urban Indonesia)
- **$\sigma_{total\ mean} = 0.755$** (rerata 103 periode) — uncertainty average untuk seluruh range gedung
- **Anchor $T=0.3, 1.0, 3.0$ s** = SNI S_S/S_1 proxy + Indonesian urban building profile (rumah mid-rise high-rise)

Referensi standar bangunan

- **SNI 1726:2019** [ref12] — Tata cara perencanaan ketahanan gempa untuk struktur bangunan gedung dan non gedung PDF: /Users/hanif/adaptive_ptw_eews/05_References/SNI 1726–2019 – Tata cara perencanaan ketahanan gempa untuk struktur bangunan gedung dan non gedung.pdf
- **ASCE/SEI 7-16** [ref13] — Minimum Design Loads and Associated Criteria for Buildings and Other Structures PDF: ASCE_7_16_Minimum_Design_Loads_for_Build.pdf
- **FEMA P-58** — Seismic Performance Assessment of Buildings (performance-based design) PDF: FEMA_P-58-1-SE_Volume1_Methodology.pdf
- **Chopra A. K. (2017)** — *Dynamics of Structures*, 5th ed. — Ch. 6 (SDOF response spectrum), Ch. 18 (multi-DOF building model) PDF: Dynamics of Structures Theory and Applications to Earthquake Engineering A.K. Chopra_NNN_bb.pdf

I.2 — τ_c (Kanamori 2005)

Persamaan umum

Periode dominan dari coda gelombang-P awal sebagai proxy magnitudo on-site:

$$\tau_c = 2\pi \sqrt{\frac{\int_0^{\tau_w} v^2(t) dt}{\int_0^{\tau_w} a^2(t) dt}} \quad (I.2.1)$$

di mana: - $v(t) = \int_0^t a(s) ds$ = velocity (integrasi akselerasi) - $a(t)$ = vertical-component acceleration - τ_w = jendela waktu observasi (0.5–3.0 s untuk EEWS)

Derivasi

Untuk sinyal monokromatik $a(t) = A \sin(\omega t)$, velocity $v(t) = -(A/\omega) \cos(\omega t)$:

$$\int_0^{T_{cycle}} v^2 dt = \frac{A^2}{2\omega^2} T_{cycle}, \quad \int_0^{T_{cycle}} a^2 dt = \frac{A^2}{2} T_{cycle}$$

Sehingga rasio = $1/\omega^2$, dan $\tau_c = 2\pi/\omega = T$ periode dominan. Untuk sinyal broadband, τ_c adalah **periode rata-rata berbobot energi** dari spektrum.

Implementasi: src/physics/feature_extractor.py:44-79

```
def compute_tau_c(acc_z: np.ndarray, dt: float) -> float:
    acc = np.asarray(acc_z, dtype=np.float64)
    vel = np.cumsum(acc) * dt          # trapezoidal integration
    int_v2 = np.sum(vel ** 2) * dt     # ∫v²dt
    int_a2 = np.sum(acc ** 2) * dt     # ∫a²dt
    tau_c = 2.0 * np.pi * np.sqrt(int_v2 / (int_a2 + _EPS))
    return float(np.clip(tau_c, 0.01, 20.0))
```

Makna fisis

- **Source corner frequency proxy:** Brune (1970) memprediksi $f_c \propto M_0^{-1/3}$. Event lebih besar f_c lebih rendah $\tau_c = 1/f_c$ lebih panjang.
- **Saturasi pada $M_w > 6.5$:** Karena τ_c dihitung pada $\tau_w = 3s$ saja, ia jenuh begitu rupture berlanjut melewati waktu observasi. Inilah mengapa τ_c saja tidak cukup untuk magnitudo besar (Lancieri & Zollo 2008).
- **Discrimination intensity local:** Meski saturated untuk magnitudo, τ_c tetap diskriminatif untuk **kelas intensitas lokal** karena event damaging M5.5 dekat-sumber tetap menghasilkan τ_c lebih panjang daripada event lemah M4.0 jauh.

Relasi ke audit

- Salah satu dari **7 fitur Stage 0 URPD** (jendela 0.5 s).
- Salah satu dari **34 base features** Stage 1 (jendela 2.0 s).
- SHAP importance: ~30% gain pada Stage 0 (lihat Tab. 6 manuscript).

I.3 — P_d (Wu & Kanamori 2005)

Persamaan umum

Peak displacement dari double integration akselerasi gelombang-P awal:

$$P_d = \max_{0 \leq t \leq \tau_w} |d(t)|, \quad d(t) = \int_0^t \int_0^s a(\xi) d\xi ds \quad (I.3.1)$$

Derivasi

Wu & Kanamori (2005, BSSA) menetapkan korelasi empiris untuk Taiwan:

$$\log_{10}(P_d) \approx 0.74 M_w - 5.30 - 1.41 \log_{10}(R) \quad (I.3.2)$$

(units: P_d dalam m, R dalam km). Korelasi ini valid hingga $M_w \approx 6.5$; saturasi muncul di atas itu karena rupture belum selesai dalam 3 detik observasi.

Implementasi: src/physics/feature_extractor.py:82-107

```
def compute_Pd(acc_z: np.ndarray, dt: float) -> float:
    acc = np.asarray(acc_z, dtype=np.float64)
    vel = np.cumsum(acc) * dt          # 1st integration: a → v
    disp = np.cumsum(vel) * dt         # 2nd integration: v → d
    return float(np.max(np.abs(disp)) + _EPS)
```

Makna fisis

- P_d menangkap **displacement near-field** dari Brune source: amplitudo lebih tinggi untuk event lebih besar.
- **Saturating** seperti τ_c untuk magnitudo besar — Lancieri & Zollo (2008) menunjukkan saturasi mulai $M_w > 6.5$.
- Konstanta 0.74 di Eq. (I.3.2) adalah regression coefficient empiris dari data SoCal/Taiwan — bukan turunan teoretis.

Relasi ke audit

- Salah satu dari **7 fitur Stage 0 URPD** (kombinasi $\tau_c + P_d$ = Wu-Kanamori-Allen 2007 threshold-based EEWS).
- Manuscript Sec 4.3: digunakan untuk routing kelas intensitas, bukan estimasi magnitudo (Feature Dichotomy).

I.4 — CAV (EPRI 1988)

Persamaan umum

Cumulative Absolute Velocity, integral nilai mutlak akselerasi sepanjang durasi event:

$$CAV = \sum_{c \in \{E, N, Z\}} \int_{t_P}^{t_{end}} |a_c(t)| dt \quad (I.4.1)$$

Derivasi

EPRI (1988) NP-5930 mengusulkan CAV sebagai threshold trigger Operating-Basis Earthquake (OBE) untuk pembangkit nuklir. Formulasi turunan: jika kita modelkan akselerasi sebagai Gaussian random process white-noise band-limited dengan PSD $S_a(f)$, maka:

$$E[CAV^2] = \frac{2}{\pi} \text{Var}(a) \tau_{eff}$$

dengan τ_{eff} = effective duration. Jadi $CAV \propto \sqrt{(\text{energy} \times \text{duration})}$ — **non-saturating** untuk rupture besar karena terus berakumulasi.

Implementasi: `src/physics/feature_extractor.py:110-136`

```
def compute_CAV(acc_3ch: np.ndarray, dt: float) -> float:
    acc = np.asarray(acc_3ch, dtype=np.float64)
    cav = np.sum(np.abs(acc)) * dt      #  $\int |a| dt$  summed over channels
    return float(cav + _EPS)
```

Makna fisis

- **Non-saturating**: berbeda dengan τ_c/P_d , CAV terus meningkat selama rupture berlangsung. Inilah dasar **Feature Dichotomy** — fitur saturating untuk klasifikasi (Stage 1), non-saturating untuk regresi (Stage 2).
- **Damage correlation**: EPRI memvalidasi CAV korelasi tinggi dengan kerusakan struktural — beberapa kode bangunan modern (mis. ASCE/SEI 41) menggunakan CAV sebagai intensity measure alternatif.
- **Operational basis earthquake**: threshold $CAV > 0.16$ g-s sering dipakai sebagai trigger evakuasi.

Relasi ke audit

- Salah satu dari **4 non-saturating energy features** di Tab. 5 manuscript (CAV, CVAD, CVAV, CVAA).
 - SHAP top-3 di Stage 2 regression (lihat Fig. 7 manuscript).
-

I.5 — IV² (Arias 1970 proxy)

Persamaan umum

Integral velocity-squared sebagai proxy Arias Intensity:

$$IV^2 = \sum_{c \in \{E, N, Z\}} \int_0^{\tau_w} v_c^2(t) dt \quad (I.5.1)$$

Arias Intensity asli (Arias 1970):

$$I_a = \frac{\pi}{2g} \int_0^\infty a^2(t) dt \quad [\text{m/s}] \quad (I.5.2)$$

Derivasi

Arias (1970) menunjukkan bahwa I_a proporsional dengan **total energi spesifik** yang dilepaskan ke osilator SDOF:

$$E_{released}(T, \zeta) \approx \frac{2\zeta}{\pi} I_a (g/\omega_0)^2$$

terintegrasi atas semua periode. IV^2 adalah varian yang dihitung di domain velocity (lebih lambat saturating).

Implementasi: src/physics/feature_extractor.py:139-169

```
def compute_IV2(acc_3ch: np.ndarray, dt: float) -> float:
    acc = np.asarray(acc_3ch, dtype=np.float64)
    iv2 = 0.0
    for ch in range(acc.shape[0]):
        vel = np.cumsum(acc[ch]) * dt      # integrate: a → v
        iv2 += np.sum(vel ** 2) * dt      # ∫v²dt per channel
    return float(iv2 + _EPS)
```

Makna fisis

- **Energy proxy** non-saturating: seperti CAV, terus terakumulasi selama event.
- **Frequency-content-sensitive**: integrasi $a \rightarrow v$ adalah low-pass filter $1/i\omega$, sehingga IV^2 lebih sensitif terhadap content frekuensi-rendah (engineering-relevant untuk bangunan tinggi).
- **Compared with Arias**: $I_a \propto \int a^2 dt$, sedangkan $IV^2 \propto \int v^2 dt$. Untuk source spectrum Brune ω^2 model, $IV^2 \approx I_a / \omega_c^2$.

Relasi ke audit

- Salah satu non-saturating Stage 2 feature (Tab. 5).
 - Pasangan dengan CAV untuk **complete Feature Dichotomy** non-saturating set.
-

I.6 — H/V ratio (Nakamura 1989)

Persamaan umum

Rasio peak horizontal-to-vertical sebagai proxy site amplification:

$$H/V = \frac{\sqrt{\max |a_E|^2 + \max |a_N|^2}}{\max |a_Z|} \quad (I.6.1)$$

Derivasi

Nakamura (1989) berargumen: di tanah lunak (soft soil), gelombang shear horizontal mengalami **resonansi** pada frekuensi natural lapisan, sementara komponen vertikal (kompresional) menyebar lebih bebas. Karena itu spektrum H/V menunjukkan puncak pada frekuensi resonansi $f_0 = V_S / (4h)$ di mana h adalah ketebalan lapisan.

Versi sederhana (peak-based) yang dipakai di sini bukan spektral H/V, tapi **scalar proxy site amplification**.

Implementasi: `src/physics/feature_extractor.py:172-202`

```
def compute_hv_ratio(acc_e, acc_n, acc_z) -> float:
    peak_e = float(np.max(np.abs(acc_e)) + _EPS)
    peak_n = float(np.max(np.abs(acc_n)) + _EPS)
    peak_z = float(np.max(np.abs(acc_z)) + _EPS)
    h_peak = np.sqrt(peak_e ** 2 + peak_n ** 2)
    return float(np.clip(np.log10(h_peak / peak_z + _EPS), -2.0, 2.0))
```

Makna fisis

- **Site class proxy**: situs di tanah lunak ($V_{S30} < 360$ m/s, Class D/E ASCE) cenderung $H/V > 1.5$ karena amplifikasi horizontal.
- **Wave-incidence-angle proxy**: gelombang yang datang miring memiliki rasio horizontal/vertikal berbeda dari gelombang vertikal.

Relasi ke audit

- **Site-path feature** pasangan dengan V_{S30} dan $\log_{10}(\Delta)$.
- Manuscript Sec 4.1 (Tab. 5) — “Site Amplification & Path” family.

I.7 — Brune source spectrum (1970)

Persamaan umum

Model Brune ω^2 untuk source spectrum dalam domain frekuensi:

$$|\dot{u}(f)| = \frac{\Omega_0}{1 + (f/f_c)^2}, \quad \Omega_0 = \frac{M_0 R_{\theta\phi} F_S}{4\pi \rho v^3 r} \quad (I.7.1)$$

di mana: - Ω_0 = low-frequency plateau (proportional to moment M_0) - f_c = corner frequency

Derivasi corner frequency

Brune (1970) menurunkan dari fault-radius r dan stress drop $\Delta\sigma$:

$$f_c = \frac{0.49 \beta}{r}, \quad r = \left(\frac{7M_0}{16\Delta\sigma} \right)^{1/3} \quad (1.7.2)$$

Mensubstitusi:

$$f_c = 0.49 \beta \left(\frac{16\Delta\sigma}{7M_0} \right)^{1/3} \propto M_0^{-1/3} \quad (1.7.3)$$

Untuk $\Delta\sigma$ konstan, $f_c \propto M_0^{-1/3}$. Karena $M_w = (2/3) \log_{10}(M_0) - 6.07$, kita dapat:

$$\log_{10}(f_c) = -\frac{1}{3} \log_{10}(M_0) + \text{const} \implies \log_{10}(f_c) \approx -0.5 M_w + C \quad (1.7.4)$$

Implementasi (implicit via τ_c)

Brune spectrum **tidak dihitung langsung** di kode, tapi τ_c adalah proxy $1/f_c$ (lihat 1.2). Persamaan 1.7.4 1.2 adalah jembatan fisis.

Manuscript Sec 4.2 (line 488): “ τ_c is a frequency-domain proxy for Brune corner-frequency” (cite \ref{ref54}).

Makna fisis

- **Source size:** corner frequency rendah event besar (lebih banyak energi di periode panjang).
- **Spectral content prediction:** untuk $Sa(T)$ di periode struktur $T > 1/f_c$, response spectrum mengikuti source amplitude $\Omega_0 \propto M_0$. Untuk $T < 1/f_c$, atenuasi $1/f^2$ mengurangi.
- **Saturasi τ_c :** konsisten dengan Brune — saat rupture berlanjut, true f_c turun, tapi observasi τ_c pada window pendek tidak menangkap perubahan itu.

Relasi ke audit

- Mekanisme fisis di balik **Feature Dichotomy** (Sec 6.6 manuscript): kenapa τ_c/P_d saturating, kenapa CAV/IV² non-saturating.

1.8 — P-S travel time & Golden Time

Persamaan umum

Untuk gelombang body di medium homogen, beda waktu kedatangan P dan S di stasiun jarak Δ :

$$t_S - t_P = \Delta \left(\frac{1}{v_S} - \frac{1}{v_P} \right) \quad (1.8.1)$$

Untuk $v_P/v_S \approx \sqrt{3}$ (Poisson solid):

$$t_S - t_P \approx 0.27 (t_P - t_0) \approx \frac{\Delta}{8 \text{ km/s}} \quad (\text{rule of thumb}) \quad (1.8.2)$$

Derivasi Golden Time constraint

Untuk EEWS dengan latency T_{latency} , observation window T_{obs} harus memenuhi:

$$T_{\text{obs},i} \leq (t_i^S - t_i^P) - T_{\text{latency}} \quad \forall i \in \text{traces} \quad (1.8.3)$$

artinya: alert harus dikeluarkan **sebelum** S-wave arrival di stasiun penerima.

Implementasi: task15_stage1_ensemble_optuna.py

Latency budget di body manuscript Sec 4.4 line 1141:

$$\begin{aligned} T_{\text{latency_total}} &= 0.5 \text{ (Stage 0)} + 2.0 \text{ (Stage 1)} + 0.1 \text{ (Stage 1.5)} \\ &\quad + 8.0 \text{ (Stage 2 max window)} + 0.05 \text{ (inference)} \\ &= 10.65 \text{ s} \end{aligned}$$

Makna fisis

- **Lead-time aktif** = $(t_S - t_P) - T_{\text{latency}}$. Untuk $\Delta = 100$ km (P-S ~ 12.5 s), lead time $\approx 12.5 - 10.65 = 1.85$ s — cukup untuk reaktor shutdown / elevator stop / gas valve closure.
- **Near-field blind zone**: $\Delta < 38$ km $\square$ $t_S - t_P < 4.8$ s $\square$ tidak cukup untuk Stage 1.5+2. Inilah motivasi **Stage 0 URPD 0.5-s binary alert** sebagai universal-coverage layer.

Relasi ke audit

- **99.44% Golden Time compliance** = fraksi 25,058 trace dengan $t_S - t_P > 10.65$ s.
 - **Blind zone reduction 71%/89%** (3811 km / 384 km) berasal dari Stage 0 alert yang tidak butuh 10.65 s.
-

I.9 — Unit conversion g gal

Persamaan

$$1 \text{ g} = 9.80665 \text{ m/s}^2 = 980.665 \text{ cm/s}^2 = 980.665 \text{ gal} \quad (1.9.1)$$

Derivasi

Definisi standard gravity g_0 (CGPM 1901): $g_0 \equiv 9.80665 \text{ m/s}^2$ exact. $1 \text{ gal} = 1 \text{ cm/s}^2$ (Galileo) = 0.01 m/s^2 .

Implementasi: src/physics/psa_calculator.py:92

$$G_{\text{MS2}} = 9.80665$$

Relasi ke audit

- **Damaging threshold PGA ≥ 0.05 g**: $0.05 \times 980.665 = 49.03 \text{ gal} \approx 49 \text{ gal}$ (Tab. 4 manuscript).
 - **SIG-BMKG boundaries**: Low < 2 gal, Med 2–50 gal, High ≥ 50 gal — semua dinyatakan dalam gal.
-

BAGIAN II — STATISTIKA GEMPA BUMI

II.1 — Atkinson–Boore GMPE log-linear

Persamaan umum

Ground Motion Prediction Equation klasik (Atkinson & Boore 2003, Boore et al. 2014):

$$\log_{10}(Sa(T)) = c_0 + c_1 M + c_2 \log_{10}(R_{eff}) + c_3 M \log_{10}(R_{eff}) + c_4 \log_{10}(V_{S30}) + c_5 M^2 + \epsilon \quad (\text{II.1.1})$$

dengan: - $R_{eff} = \sqrt{(R^2 + h^2)}$, h = near-source saturation distance (~ 10 km) - $\epsilon \sim N(0, \sigma^2_{total})$ = random residual

Derivasi parameter

Setiap koefisien c_i mewakili fisika berbeda: - $c_1 M$, $c_5 M^2$ = magnitude scaling (Brune source size) - $c_2 \log R_{eff}$ = geometric spreading ($\sim 1/R$ untuk body waves) - $c_3 M \cdot \log R$ = interaction term (rupture length effect) - $c_4 \log V_{S30}$ = site amplification (NGA-West2 V_{S30} scaling)

Implementasi: task16_gmpe_baseline.py:70-90

```
def gmpe_features(df: pd.DataFrame) -> np.ndarray:
    M = df["source_magnitude"].values.astype(np.float64)
    R = df["path_ep_distance_km"].values.astype(np.float64)
    VS30 = df["station_vs30_ms"].values.astype(np.float64)

    Reff = np.sqrt(R ** 2 + H_SATURATION_KM ** 2) # H_SATURATION_KM = 10.0
    log10_Reff = np.log10(Reff + EPS)
    log10_VS30 = np.log10(np.clip(VS30, 100.0, 2000.0))

    X = np.column_stack([
        np.ones_like(M), # c_0 intercept
        M, # c_1 magnitude linear
        log10_Reff, # c_2 distance
        M * log10_Reff, # c_3 mag-distance interaction
        log10_VS30, # c_4 site
        M ** 2, # c_5 magnitude saturation
    ])
    return X
```

Fitted via `LinearRegression()` (OLS) per period per fold.

Makna fisis

- **Theoretical baseline:** GMPE adalah benchmark “physics-only, no ML”. Headline $\Delta R^2 = +0.067$ IDA-PTW vs GMPE membuktikan ensemble ML menambah informasi di atas hubungan fisika.
- **Saturation distance h :** mencegah $\log(R)$ divergen saat $R \rightarrow 0$. Untuk subduksi Indonesia $h \approx 10$ km sesuai BC Hydro.

Relasi ke audit

- **GMPE $R^2 = 0.6423$** (output task16_gmpe_baseline.json).
- **$\Delta R^2 = 0.7091 - 0.6423 = 0.0668 \approx +0.067$** (derivation check #1 di numbers_audit_report).

II.2 — AI Atik (2010) sigma decomposition

Persamaan umum

Residual ϵ_{ij} event i station j didekomposisi menjadi inter-event + intra-event:

$$\epsilon_{ij} = \eta_i + \delta_{ij}, \quad \eta_i \sim N(0, \tau^2), \quad \delta_{ij} \sim N(0, \phi^2) \quad (\text{II.2.1})$$

dengan asumsi $\text{cov}(\eta_i, \delta_{ij}) = 0$. Total varians:

$$\sigma_{total}^2 = \tau^2 + \phi^2 \quad (\text{II.2.2})$$

Derivasi mixed-effects model

Untuk per-period regression $y_{ij} = X_{ij}\beta + \epsilon_{ij}$ dengan random effect event η_i :

$$y_{ij}|\eta_i = X_{ij}\beta + \eta_i + \delta_{ij}, \quad y \sim N(X\beta, \tau^2 J_n + \phi^2 I_n)$$

di mana J_n = block-diagonal indicator events. REML maximum likelihood estimate $\hat{\tau}^2$, $\hat{\phi}^2$ via Newton-Raphson (AI Atik 2010, Section 3).

Implementasi: task4_sigma_decomposition.py:111-123

```
if HAS_STATSMODELS and len(np.unique(gm)) > 10:
    dres = pd.DataFrame({"r":residuals,"e":gm})
    mdl = smf.mixedlm("r ~ 1", dres, groups=dres["e"]) # mixedLM with event groups
    fit = mdl.fit(method="lbfgs", reml=True) # REML fit via L-BFGS
    tau2 = float(fit.cov_re.iloc[0,0]) # event variance
    phi2 = float(fit.scale) # residual variance
    sigma2= tau2 + phi2

# fallback (method-of-moments):
def decompose_mom(residuals, events):
    dfres = pd.DataFrame({"r":residuals,"e":events})
    event_means = dfres.groupby("e")["r"].mean()
    tau2 = event_means.var(ddof=0) # tau^2
    phi2 = (dfres["r"] - dfres["e"].map(event_means)).var(ddof=0) # phi^2
    sigma2 = residuals.var(ddof=0)
    return tau2, phi2, sigma2
```

Makna fisis & statistis

- **τ (inter-event)**: variabilitas yang **konstan untuk event yang sama** — mewakili source-to-source differences (stress drop variability, focal mechanism, depth).
- **ϕ (intra-event)**: variabilitas yang **berbeda per station** dalam event yang sama — mewakili site-path effects (V_{S30} mis-estimation, basin effects, directivity).
- **Dominansi ϕ** : untuk dataset IDA-PTW, $\phi^2/\sigma^2 = 62.8\%$ mayoritas residual berasal dari ketidakpastian site-path, bukan source. Inilah mengapa **HVSR/ V_{S30} measurement campaign** adalah next-priority improvement (Sec 6.7 manuscript).

Relasi ke audit

- **Tab. 17 manuscript** = output direct sigma_decomposition.csv.
- Verifikasi $\sigma_{total} = \sqrt{(\tau^2 + \phi^2)}$: $0.8618 \approx 0.862$ (derivation check #2).
- Mean $\sigma_{total} = 0.7532 \approx 0.755$ (check #3).

II.3 — Marginalized R² over Stage-1 posterior

Persamaan umum

Stage 2 menghasilkan 3 prediksi conditional (per kelas intensitas $c \in \{L, M, H\}$):

$$\hat{y}^{(c)} = f_c(X) \quad (\text{class-conditional regressor}) \quad (\text{II.3.1})$$

Stage 1 memberikan posterior $p_k = P(c=k \mid X)$. Marginalized prediction:

$$\hat{y}^{arg} = \sum_{k \in \{L, M, H\}} p_k \cdot \hat{y}^{(k)} = \mathbb{E}_{c \sim p} [\hat{y}^{(c)}] \quad (\text{II.3.2})$$

Derivasi

Decision theory: jika c benar tapi tidak diobservasi, pilihan prediksi yang meminimumkan expected squared loss:

$$\hat{y}^*(X) = \arg \min_{\hat{y}} \mathbb{E}_{c|X} [(y(c) - \hat{y})^2]$$

Solusi: $\hat{y}^* = E[y|X] = \sum_k p_k \cdot f_k(X)$. Inilah formula marginalisasi (II.3.2).

Tiga varian R² yang dilaporkan

1. **Marginalized** (II.3.2): seperti di atas, soft posterior weighting **R² = 0.7091** (headline)
2. **Argmax routing**: $\hat{y} = f_{\{\arg\max_k p_k\}}(X)$ **R² = 0.6785** (rute hanya ke kelas paling mungkin)
3. **Oracle UB**: $\hat{y} = f_{\{c_{\{\text{true}\}}\}}(X)$ dengan label sejati **R² = 0.7779** (upper bound jika klasifikasi sempurna)

Gap $0.7779 - 0.7091 = 0.069$ = “routing uncertainty penalty”.

Implementasi: task15_stage1_ensemble_optuna.py:427-431

```
# pp_te shape (n_test, 3) = Stage-1 ensemble posterior
# cond shape (3, n_test, 103) = Stage-2 class-conditional predictions

marg = np.einsum("nk,knp->np", pp_te, cond) # II.3.2 marginalized

argmax_pred = np.take_along_axis(
    cond, yp_te[None, :, None].repeat(P, axis=2), axis=0)[0] # argmax route

oracle_pred = np.take_along_axis(
    cond, y_cls[te][None, :, None].repeat(P, axis=2), axis=0)[0] # oracle
```

Makna statistis

- **Marginalisasi = optimal posterior-weighted prediction** assuming class probabilities calibrated.
- **Argmax < Marginalized < Oracle**: marginalized strictly better daripada argmax karena memanfaatkan soft confidence; tetap di bawah oracle karena Stage 1 tidak sempurna (BAcc 81.68% < 100%).
- **Routing penalty (0.069)** = anggaran ketidakpastian eksplisit — mengkuantifikasi cost dari klasifikasi imperfect.

Relasi ke audit

- **Headline $R^2 = 0.7091$** = composite_all.R2_marginalized di ida_ptw_task15.json.
 - **Operational $R^2 = 0.6962$** = sama tapi marginalized hanya pada $T \leq 2$ s (42 periode).
-

II.4 — Balanced accuracy (multi-class)

Persamaan

Untuk klasifikasi K-kelas dengan support tidak seimbang:

$$B\text{Acc} = \frac{1}{K} \sum_{k=1}^K \text{Recall}_k = \frac{1}{K} \sum_{k=1}^K \frac{TP_k}{TP_k + FN_k} \quad (\text{II.4.1})$$

Derivasi vs accuracy biasa

Accuracy biasa: $\text{Acc} = (\sum TP_k) / N$. Untuk dataset imbalanced (Low=6592, Med=14792, High=2153, ratio 3.06:1 Low/High), classifier yang selalu predict Med dapat punya Acc ~63% tanpa mengenali High (Damaging) sama sekali.

Balanced accuracy mengaverage recall **per kelas** secara seragam, sehingga classifier yang miss High akan dipenalti.

Implementasi: task15_stage1_ensemble_optuna.py:392

```
from sklearn.metrics import balanced_accuracy_score
bacc_ens = balanced_accuracy_score(y_cls[te], yp_te)
```

Makna safety-relevant

- BAcc = 81.68% (ensemble) vs Acc = 79.64% — perbedaan kecil tapi BAcc penalize “ignoring minority class”.
- Untuk EEWS, recall High (Damaging) **lebih penting** daripada precision — false alarm acceptable, missed alarm catastrophic.

Relasi ke audit

- **Headline BAcc 81.68%** dengan ratio 3.06:1 imbalance — bukti classifier tidak hanya predict mayoritas.
 - High-class recall $\approx 86\%$ (Tab. 11) menunjukkan SMOTE + class weight bekerja.
-

BAGIAN III — MACHINE LEARNING

III.1 — XGBoost objective

Persamaan umum

Untuk training set $\{(x_i, y_i)\}_{i=1}^N$, XGBoost meminimumkan:

$$\mathcal{L}(\phi) = \sum_{i=1}^N \ell(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k) \quad (\text{III.1.1})$$

dengan **regularization term** per tree:

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda \|w\|^2 + \alpha \|w\|_1 \quad (\text{III.1.2})$$

di mana: - T = jumlah leaf di tree - w = leaf weights - γ = leaf-count penalty (controls tree complexity) - λ = L2 regularization (Ridge-like) - α = L1 regularization (Lasso-like, induces sparsity)

Derivasi second-order Taylor expansion

Untuk loss $\ell(y, \hat{y})$ differentiable dua kali, XGBoost approximate (Chen & Guestrin 2016):

$$\ell(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) \approx \ell(y_i, \hat{y}_i^{(t-1)}) + g_i f_t(x_i) + \frac{1}{2} h_i f_t(x_i)^2$$

dengan $g_i = \partial \ell / \partial \hat{y}$, $h_i = \partial^2 \ell / \partial \hat{y}^2$. Substitute ke (III.1.1):

$$\tilde{\mathcal{L}}^{(t)} = \sum_i \left[g_i f_t(x_i) + \frac{1}{2} h_i f_t(x_i)^2 \right] + \Omega(f_t)$$

Untuk tree dengan leaf score w_j di leaf j , summation atas instance I_j (yang fall di leaf j):

$$\tilde{\mathcal{L}}^{(t)} = \sum_{j=1}^T \left[\left(\sum_{i \in I_j} g_i \right) w_j + \frac{1}{2} \left(\sum_{i \in I_j} h_i + \lambda \right) w_j^2 + \alpha |w_j| \right] + \gamma T$$

Optimal leaf weight (closed-form for L2-only case):

$$w_j^* = - \frac{\sum_{i \in I_j} g_i}{\sum_{i \in I_j} h_i + \lambda} \quad (\text{III.1.3})$$

Implementasi: manuscript Sec 4.5 + task15:366-371

```
xgb_clf = xgb.XGBClassifier(
    **best_xgb_params,          # n_estimators, max_depth, lr, subsample, colsample, min_child_w
    objective="multi:softprob", num_class=3,
    random_state=SEED, n_jobs=-1, verbosity=0, tree_method="hist",
)
```

Hyperparameter konsensus (dari Optuna 30 trials, di ida_ptw_task15.json): - $n_estimators = 300$ - $max_depth = 5$ - $learning_rate = 0.043$ - $subsample = 0.721$ - $colsample_bytree = 0.748$ - $min_child_weight = 5$

Manuscript Sec 4.5 (line 669): > "Log-scale targets follow GMPE convention [ref48, ref62]. $\gamma = 0$ (no leaf penalty), $\lambda = 1.0$ (L2), $\alpha = 0.1$ (L1)."

Makna ML-statistik

- **Regularization triad** (γ, λ, α): mencegah overfit dengan menghukum tree complexity (γ), leaf magnitude (λ), dan inducing sparsity (α).
- **Second-order Taylor** lebih cepat konvergen daripada first-order gradient boosting (Friedman 2001) — terkonfirmasi di XGBoost benchmarks.
- **Feature weights** (manuscript Sec 4.5): $feature_weights = 0.2$ untuk fitur saturating (τ_c, P_d, P_v) 5x downweighted SHAP mengurangi bias pada event besar.

Relasi ke audit

- 5 hyperparameter ini direproduksi exact di FULL re-run (drift 0).
 - 90 fitur input 103-period output via `MultiOutputRegressor(XGBRegressor)` di Stage 2.
-

III.2 — Gradient boosting recursion

Persamaan

Iterative ensemble update:

$$\hat{y}^{(t)}(x) = \hat{y}^{(t-1)}(x) + \eta f_t(x), \quad f_t \in \mathcal{F} \text{ (CART trees)} \quad (\text{III.2.1})$$

dengan η = learning rate (=0.043 untuk task15).

Derivasi

Friedman (2001): gradient boosting adalah functional gradient descent di ruang fungsi. Untuk loss L , the gradient direction adalah $-\partial L / \partial \hat{y} = -g_i$. Tree f_t di-fit untuk **mendekati** gradient negatif, lalu di-scale dengan η (shrinkage).

Untuk multi-class softprob:

$$L = - \sum_i \sum_k \mathbb{1}[y_i = k] \log p_{ik}, \quad p_{ik} = \frac{\exp(\hat{y}_{ik})}{\sum_{k'} \exp(\hat{y}_{ik'})}$$

dengan $\hat{y}_{ik}$ = logit kelas k . Gradient:

$$g_{ik} = p_{ik} - \mathbb{1}[y_i = k]$$

Hessian:

$$h_{ik} = p_{ik}(1 - p_{ik})$$

Implementasi (implicit via XGB library)

XGBoost mengimplementasikan ini dalam C++ — tidak ditulis ulang di Python. Konsumsi via `xgb.XGBClassifier(objective=`

Makna ML

- **Shrinkage η** : 0.04 (FULL) vs 0.05 (default) — kecil konvergen lebih lambat tapi generalisasi lebih baik (analog ke step size SGD).
- **300 trees × shrinkage 0.043** = effective capacity ~13 trees worth moderate complexity, bagus untuk $N=23,537$.

Relasi ke audit

- Optuna mencari kombinasi (`n_est`, `depth`, η , `subsample`, `colsample`, `min_child_w`) yang memaksimalkan validation AUC `n_estimators=300`, `lr=0.0432` adalah best.
-

III.3 — SMOTE

Persamaan

Synthetic Minority Oversampling Technique (Chawla et al. 2002): untuk setiap sample minority x_i , pilih random k-nearest neighbor x_{nn} , lalu generate sintetik:

$$x_{new} = x_i + \lambda(x_{nn} - x_i), \quad \lambda \sim \text{Uniform}(0, 1) \quad (\text{III.3.1})$$

Derivasi

SMOTE menambah varietas di kelas minoritas dengan **interpolasi linear** di feature space. Asumsi: feature space lokal smooth interpolasi antar tetangga memberikan plausible synthetic example.

Untuk class High (N=2,153 di task15 subset) di-oversample hingga ratio $\approx 1:1$ dengan kelas dominan:

Pre-SMOTE: Low=6,592 Med=14,792 High=2,153
Post-SMOTE: Low= $\sim 5,300$ Med= $\sim 11,800$ High= $\sim 5,900$ ($\approx 2.7\times$ upsample High)

Implementasi: task15:354-356

```
from imblearn.over_sampling import SMOTE
X_tr_smote, y_tr_smote = smote_minority(
    X_all[tr], y_cls[tr], minority_class=2, seed=SEED)
```

di mana smote_minority adalah wrapper sederhana:

```
def smote_minority(X, y, minority_class=2, seed=42):
    smote = SMOTE(sampling_strategy={minority_class: ...},
                  random_state=seed, k_neighbors=5)
    return smote.fit_resample(X, y)
```

Makna ML

- **Mencegah classifier “ignore minority”**: tanpa SMOTE, gradient boosting cenderung memaksimalkan accuracy pada kelas mayoritas (Med).
- **Bukan oversampling duplikasi** — SMOTE adalah *interpolated* oversampling, less overfit-prone daripada sample with replacement.
- **Safety-relevant**: minority class adalah **Damaging events** — tidak mengenalinya = miss safety alert.

Relasi ke audit

- Hanya diaplikasikan ke **training fold**, tidak ke test fold (cegah leakage).
- Per-fold post-SMOTE distribution dilaporkan di log task15.

III.4 — Soft voting ensemble

Persamaan

Untuk dua classifier (XGB, LGB) menghasilkan probability $p^{\{XGB\}}(c|x)$ dan $p^{\{LGB\}}(c|x)$, ensemble soft-voting:

$$p^{(ens)}(c|x) = w_{XGB} p^{(XGB)}(c|x) + w_{LGB} p^{(LGB)}(c|x), \quad w_{XGB} + w_{LGB} = 1 \quad (\text{III.4.1})$$

Pilihan kelas final: $\hat{c} = \text{argmax}_c p^{\{ens\}}(c|x)$.

Derivasi

Soft voting optimal jika: 1. Klasifier punya **calibrated probabilities** ($p_k(c|x) \approx P(c|x)$ sejati) 2. Klasifier **independen** (tidak korelasi error) 3. Bobot w_k proporsional terhadap inverse error variance

Untuk task15, $w_{\{XGB\}} = w_{\{LGB\}} = 0.5$ (equal — empirical compromise tanpa Bayesian tuning).

Implementasi: task15:387

```
pp_te = 0.5 * pp_xgb + 0.5 * pp_lgb      # soft voting average
yp_te = pp_te.argmax(1).astype(int)
```

Makna ML

- **Bias reduction:** XGB dan LGB pakai algoritma boosting berbeda (XGB level-wise vs LGB leaf-wise) error pattern berbeda averaging mengurangi varians.
- **Empirical gain:** di task15 per-fold, XGB alone fold acc ≈ 0.79 , LGB alone ≈ 0.80 , ensemble ≈ 0.80 – 0.82 .

Relasi ke audit

- Headline **BAcc 81.68%** adalah ensemble output, bukan XGB-saja atau LGB-saja.
- Konfirmasi di log task15 FULL run: per-fold ensemble bacc 0.81–0.82.

III.5 — TPE Optuna

Persamaan

Tree-structured Parzen Estimator (Bergstra et al. 2011) untuk hyperparameter optimization. Modelkan distribusi:

$$p(\theta|D) \propto \begin{cases} \ell(\theta) & \text{if } \text{objective}(\theta) < y^* \\ g(\theta) & \text{otherwise} \end{cases}$$

dengan y^* quantile threshold (default $\gamma = 0.25$). Sample next trial dari $\arg\max_{\theta} \square(\theta)/g(\theta)$ (Expected Improvement criterion).

Derivasi Expected Improvement

$$\text{EI}(\theta) = \mathbb{E}_{y \sim p(y|\theta)}[\max(y^* - y, 0)]$$

Untuk TPE distribution:

$$\text{EI}(\theta) \propto \frac{\ell(\theta)}{\gamma + (1 - \gamma) \frac{g(\theta)}{\ell(\theta)}}$$

Maximize EI = pilih θ dengan $\square(\theta)/g(\theta)$ tinggi high under “good” distribution, low under “bad”.

Implementasi: task15:111-152

```
def optuna_tune_xgb(X_tr, y_tr, groups_tr, n_trials: int, seed: int):
    def objective(trial):
        params = {
            'n_estimators': trial.suggest_int('n_estimators', 100, 500),
            'max_depth': trial.suggest_int('max_depth', 3, 10),
            'learning_rate': trial.suggest_float('learning_rate', 0.01, 0.1, log=True),
```

```

        'subsample': trial.suggest_float('subsample', 0.6, 1.0),
        ...
    }
    clf = xgb.XGBClassifier(**params, random_state=seed, ...)
    score = cross_val_score(clf, X_tr, y_tr, groups=groups_tr,
                            cv=GroupKFold(N_SPLITS), scoring='roc_auc_ovr_weighted')
    return score.mean()

study = optuna.create_study(direction='maximize',
                            sampler=optuna.samplers.TPESampler(seed=seed))
study.optimize(objective, n_trials=n_trials)
return study.best_params

```

Makna optimization

- **TPE > random search** untuk dim sedang (6 hyperparameter): convergence 5-10x lebih cepat.
- **TPESampler(seed=42)**: deterministic search reproducible best params.
- **30 trials** menemukan optimum lokal cukup baik untuk dim=6.

Relasi ke audit

- Best params task15 (FULL re-run): exact match canonical konfirmasi TASK15_OPTUNA_TRIALS=30 + seed=42 reproducible.

BAGIAN IV — OPERASIONAL & OPTIMASI

IV.1 — Multi-objective Lagrangian

Persamaan

Manuscript Sec 4.4 (line 239, “Multi-objective optimization formulation”):

$$\mathcal{L}_{total} = \mathcal{L}_{RMSE} + \lambda_{recall} \cdot \mathcal{L}_{recall} \quad (IV.1.1)$$

dengan kendala:

$$T_{obs,i} \leq (t_i^S - t_i^P) - T_{latency} \quad \forall i \quad (\text{Golden Time}) \quad (IV.1.2)$$

di mana: - $\mathcal{L}_{RMSE} = (1/N) \sum_{i,T} (\log_{10} Sa_{pred}(T) - \log_{10} Sa_{obs}(T))^2$ — primary spectral accuracy
- $\mathcal{L}_{recall} = 1 - Recall(\text{Damaging})$ — penalty Stage 0/1 misclassification

Derivasi

Lagrangian formulation untuk constrained multi-objective:

$$\arg \min_{\theta} \mathcal{L}_{RMSE}(\theta) \quad \text{s.t.} \quad \mathcal{L}_{recall}(\theta) \leq \epsilon, \quad T_{obs} \leq T_{budget}$$

Diubah ke unconstrained via Lagrange multiplier λ_{recall} :

$$\arg \min_{\theta} \mathcal{L}_{RMSE}(\theta) + \lambda_{recall} \max(\mathcal{L}_{recall}(\theta) - \epsilon, 0)$$

λ_{recall} tinggi emphasize Damaging recall (safety-first).

Implementasi (logical, distributed across tasks)

Tidak ada satu file dengan Lagrangian penuh — terdistribusi: - L_{RMSE} di `task15_stage1_ensemble_optuna.py:103-104` sebagai XGB regression objective `reg:squarederror on log10 Sa`. - L_{recall} enforced via SMOTE oversampling kelas High (Sec III.3) + class weights $cls_w = N_{total} / (3 \cdot N_{class})$ di line 362. - Golden Time constraint via window size selection $T_{obs} \in \{3, 5, 8\}$ s per kelas (Sec IV.2).

Makna design philosophy

- **Tidak ada λ_{recall} numerik eksplisit** — diimplementasikan struktural via dataset balancing + window adaptation.
- **Safety-first**: penalty miss Damaging > penalty over-predict — manuscript Sec 5.1 secara eksplisit menyatakan trade-off ini.

Relasi ke audit

- Recall High class Stage 1 $\approx 86\%$ (Tab. 11) = bukti L_{recall} penalty bekerja.
- Latency total ≤ 10.65 s = bukti constraint Golden Time di-enforce.

IV.2 — Adaptive PTW selection rule

Persamaan

Stage 1 mengeluarkan kelas posterior (p_L , p_M , p_H). Window length untuk Stage 2 dipilih:

$$T_{obs}(X) = \begin{cases} 3 \text{ s} & \text{if } \text{argmax}(p) = \text{Low} \\ 5 \text{ s} & \text{if } \text{argmax}(p) = \text{Medium} \\ 8 \text{ s} & \text{if } \text{argmax}(p) = \text{High (Damaging)} \end{cases} \quad (\text{IV.2.1})$$

Derivasi

Trade-off antara latency dan akurasi: - **Low intensity** tidak perlu observasi lama (event lemah, fitur sudah cukup untuk regression accurate) - **High intensity (Damaging)** butuh lebih banyak waveform untuk capture rupture berlangsung (mengatasi saturasi τ_c/P_d)

Adaptasi class-conditional = **conditional sampling** dari ruang waktu observasi, sehingga sistem menyalurkan resource (latency budget) ke event yang butuh.

Implementasi (via class-conditional Stage 2)

`task15_stage1_ensemble_optuna.py:398-408`: training 3 regressor terpisah per kelas:

```
for c in range(3):
    mask = (y_cls[tr] == c)
    X_tr_c, Y_tr_c = X_all[tr][mask], Y_log[tr][mask]
    reg_xgb = MultiOutputRegressor(xgb.XGBRegressor(
        n_estimators=n_reg, max_depth=depth, learning_rate=0.04,
        subsample=0.8, colsample_bytree=0.8, min_child_weight=8,
        random_state=SEED, n_jobs=-1, verbosity=0, tree_method="hist",
    ))
    reg_xgb.fit(X_tr_c, Y_tr_c)
    pred_xgb = reg_xgb.predict(X_all[te]).astype(np.float32)
    cond[c] = pred_xgb
```

Setiap regressor reg_c belajar dari **fitur yang diekstrak pada window-length-yang-sesuai** untuk class c (window 3s untuk Low, 5s Med, 8s High). Inilah **adaptive PTW**.

Makna physical adaptation

- **Saturation-aware**: untuk Damaging events, window 8s memberikan cukup waveform setelah τ_c saturasi CAV/IV² accumulate adequate energi.
- **Universal coverage compromise**: Low events selesai dalam 3s tidak perlu tunggu 8s operational alert lebih cepat.
- **Latency budget allocation**: rata-rata 1.5 dari (3+5+8)/3 = 5.3 s per kelas — meskipun max 8s.

Relasi ke audit

- 3 regressors $\times$ 103 periode = **309 Stage-2 models** (dari task15. json per_fold detail).
- Adaptive window adalah **kontribusi novelty utama** manuscript (IDA-PTW name itself: Intensity-Driven Adaptive PTW).

RINGKASAN: PERSAMAAN ANGKA HEADLINE

Tabel ringkas hubungan setiap persamaan dengan angka final di audit:

Persamaan	Bagian	Headline number didukung
Sa (T) Nigam-Jennings (I.1) T tinggi gedung (I.1a)	Fisika Engineering seismology	103 periode target, $R^2=0.7091$ T=1.0 s anchor untuk mid-rise; rule $T \approx 0.1N$; SNI S-S/S_1 mapping
τ_c (I.2)	Fisika	Salah satu 7 fitur Stage 0 AUC=0.9136
P_d (I.3)	Fisika	Wu-Kanamori-Allen 2007 threshold-based EEWS
CAV (I.4)	Fisika	Non-saturating Stage 2 feature, dominasi SHAP
IV ² (I.5)	Fisika	Pasangan dengan CAV (Arias proxy)
H/V (I.6)	Fisika	Site amplification feature
Brune (I.7)	Fisika	Fisika di balik Feature Dichotomy
P-S timing (I.8)	Fisika	Latency 10.65 s, Golden Time 99.44%
g/gal (I.9)	Fisika	PGA threshold 0.05g = 49 gal
GMPE log-linear (II.1)	Statistika	GMPE $R^2=0.6423$, $\Delta R^2=+0.067$
AI Atik decomp (II.2)	Statistika	$\sigma_{total}=0.862$, $\tau=0.515$, $\phi=0.691$
Marginalized R ² (II.3)	Statistika	$R^2=0.7091$ (vs argmax 0.6785, oracle 0.7779)
Balanced accuracy (II.4)	Statistika	BAcc=81.68%
XGBoost objective (III.1)	ML	Hyperparams n_est=300, depth=5, lr=0.043
Gradient boost (III.2)	ML	Stage 2 spectral regression
SMOTE (III.3)	ML	Damaging recall 86% di Stage 1
Soft voting (III.4)	ML	Ensemble XGB+LGB BAcc gain ~1-2%
TPE Optuna (III.5)	ML	Hyperparameter convergence di 30 trials
Lagrangian (IV.1)	Operasional	Multi-objective safety-first design
Adaptive PTW (IV.2)	Operasional	Windows {3, 5, 8} s — novelty utama

REFERENSI LITERATUR UTAMA

Setiap persamaan punya sumber primer:

1. **Arias, A. (1970)** — A measure of earthquake intensity. MIT Press.
2. **Brune, J. N. (1970)** — Tectonic stress and the spectra of seismic shear waves. JGR 75(26).
3. **Nigam, N. C. & Jennings, P. C. (1969)** — Calculation of response spectra. BSSA 59(2).
4. **EPRI (1988)** — A criterion for determining exceedance of the operating basis earthquake. NP-5930.
5. **Nakamura, Y. (1989)** — A method for dynamic characteristics estimation using microtremor. RTRI 30(1).
6. **Kanamori, H. (2005)** — Real-time seismology and earthquake damage mitigation. Annu. Rev. Earth Planet. Sci. 33.
7. **Wu, Y.-M. & Kanamori, H. (2005)** — Experiment on an onsite early warning method. BSSA 95(1).
8. **Wu, Y.-M., Kanamori, H., Allen, R. M. & Hauksson, E. (2007)** — Determination of τ_c and P_d . BSSA 97(5).
9. **Atkinson, G. M. & Boore, D. M. (2003)** — Empirical ground-motion relations for subduction-zone. BSSA 93(4).
10. **Boore, D. M., Stewart, J. P., Seyhan, E. & Atkinson, G. M. (2014)** — NGA-West2 equations. Earthquake Spectra 30(3).
11. **Al Atik, L., Abrahamson, N., Bommer, J. J., et al. (2010)** — The variability of ground-motion prediction models. SRL 81(5).
12. **Chen, T. & Guestrin, C. (2016)** — XGBoost: A scalable tree boosting system. KDD.
13. **Friedman, J. H. (2001)** — Greedy function approximation: A gradient boosting machine. Annals of Statistics 29(5).
14. **Chawla, N. V. et al. (2002)** — SMOTE. JAIR 16.
15. **Bergstra, J. et al. (2011)** — Algorithms for hyper-parameter optimization. NeurIPS.
16. **Lancieri, M. & Zollo, A. (2008)** — A Bayesian approach to real-time magnitude estimation. JGR 113.
17. **Chopra, A. K. (2017)** — Dynamics of Structures, 5th ed. Pearson.

PDF dari semua referensi ini tersedia di /Users/hanif/adaptive_ptw_eews/05_References/ (139 file PDF dengan 65 HIGH-confidence match per bib_pdf_mapping.md).

CERTIFICATION

Setiap persamaan di manuscript v59:

- Memiliki **derivasi dari literatur primer** (16 referensi utama di atas)
- **Diimplementasikan** di source code dengan line-reference eksplisit
- Mendukung **angka headline** dengan jejak audit terverifikasi
- **Reproducible** — semua kode tersedia di hanif7108/IDA-PTW commit 61fba0f (private, akses via editor pada peer review)

Untuk konsumsi sidang doktor: - Setiap pertanyaan “darimana persamaan X?” Bagian I-IV di atas dengan derivasi penuh - Setiap pertanyaan “implementasi di mana?” file:line reference - Setiap pertanyaan “makna fisis?” blok “Makna fisis” di setiap entry

Generated: 2026-05-14 **Companion document:** EVIDENCE_v59_numbers.md **Source code:** src/physics/*.py + github_publication_v40/scripts/task*.py **Reference library:** /Users/hanif/adaptive_ptw_eews/05_Referen